
第六章：支持向量机

张自力

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数

□ 6.4 软间隔与正则化

□ 6.5 支持向量回归

□ 6.6 核方法

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数


□ 6.4 软间隔与正则化

□ 6.5 支持向量回归

□ 6.6 核方法


引子

线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开。




引子

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?




引子

-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?



-A: 应选择“正中间”, 容忍性好, 鲁棒性高, 泛化能力最强.

6.1 间隔与支持向量




已知超平面 $w_1x_1 + w_2x_2 + \dots + w_Nx_N + b = 0$ 和点 x ，其中 $x = (x_1, x_2, \dots, x_N)$ ，则这个点到这个超平面的距离为：

$$\frac{|\omega_1x_1 + \omega_2x_2 + \dots + \omega_Nx_N + b|}{\sqrt{\omega_1^2 + \omega_2^2 + \dots + \omega_N^2}}$$

可以向量表示为 $\frac{|\omega^T x + b|}{\|\omega\|}$ 。


6.1 间隔与支持向量

超平面方程: $w^\top x + b = 0$



线性可分情况下的线性分类器，这是最原始的SVM，最核心的思想就是最大的分类间隔。

6.1 间隔与支持向量



当 $w^T x + b \geq 1$ 时, $y = 1$, 正样本;
当 $w^T x + b \leq -1$ 时, $y = -1$, 负样本;
将两个式子统一起来, $y(w^T x + b) \geq 1$ 。

6.1 支持向量机基本型

□ 最大间隔：寻找参数 \mathbf{w} 和 b , 使得 γ 最大.

$$\begin{aligned} \arg \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



$$\begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数

□ 6.4 软间隔与正则化

□ 6.5 支持向量回归

□ 6.6 核方法

6.2 对偶问题

□ 拉格朗日乘子法

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 \mathbf{w} 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

6.2 对偶问题

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

那么问题就变成了：

$$\min_{\mathbf{w}, b} \max_{\boldsymbol{\alpha}} L(\mathbf{w}, b, \boldsymbol{\alpha})$$

所谓的对偶问题就是：

$$\max_{\boldsymbol{\alpha}} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$$

6.2 对偶问题

□ 第二步 -> 第三步

$$w = \sum_{i=1}^m \alpha_i y_i x_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

$$\begin{aligned} L(w, b, a) &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^n a_i (y_i (w^T \cdot x_i + b) - 1) \\ &= \frac{1}{2} w^T w - w^T \sum_{i=1}^n a_i y_i x_i - b \sum_{i=1}^n a_i y_i + \sum_{i=1}^n a_i \\ &= \frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n a_i a_j y_i y_j x_i x_j - \sum_{j=1}^n \sum_{i=1}^n a_i a_j y_i y_j x_i x_j + \sum_{i=1}^n a_i \\ &= \sum_{i=1}^n a_i - \frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n a_i a_j y_i y_j x_i x_j \end{aligned}$$

http:

6.2 解的稀疏性

□ 最终模型: $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \boxed{\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x}} + b$

□ KKT条件:

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.

6.2 求解方法 - SMO

□ 基本思路：不断执行如下两个步骤直至收敛。

- 第一步：选取一对需更新的变量 α_i 和 α_j 。
- 第二步：固定 α_i 和 α_j 以外的参数，求解对偶问题更新 α_i 和 α_j 。


□ 仅考虑 α_i 和 α_j 时，对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$

用一个变量表示另一个变量，回代入对偶问题可得一个单变量的二次规划，该问题具有闭式解。

□ 偏移项 b ：通过支持向量来确定。

6.2 实例



6.2 实例

$x_1(3,3), x_2(4,3), x_3(1,1), y_1 = y_2 = 1, y_3 = -1.$

$$\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i$$

$$i=1, j=1: \alpha_1 \alpha_1 y_1 y_1 x_1^\top x_1 = \alpha_1 \alpha_1 (1)(1)(3;3)^\top (3;3) \\ = \alpha_1 \alpha_1 (9+9) = 18\alpha_1^2$$

$$j=2: \alpha_1 \alpha_2 y_1 y_2 x_1^\top x_2 = \alpha_1 \alpha_2 (1)(1)(3;3)^\top (4;3) \\ = \alpha_1 \alpha_2 (12+9) = 21\alpha_1 \alpha_2$$

$$j=3: \alpha_1 \alpha_3 y_1 y_3 x_1^\top x_3 = \alpha_1 \alpha_3 (1)(-1)(3;3)^\top (1;1) \\ = \alpha_1 \alpha_3 (-1)(3+3) = -6\alpha_1 \alpha_3$$

6.2 实例

$$\mathbf{x}_1(3,3), \mathbf{x}_2(4,3), \mathbf{x}_3(1,1), y_1 = y_2 = 1, y_3 = -1.$$

$$\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i$$

$$\begin{aligned} i=2, j=1: \quad \alpha_2 \alpha_1 y_2 y_1 \mathbf{x}_2^\top \mathbf{x}_1 &= \alpha_2 \alpha_1 (1)(1)(4; 3)^\top (3; 3) \\ &= \alpha_1 \alpha_2 (12 + 9) = 21 \alpha_1 \alpha_2 \end{aligned}$$

$$\begin{aligned} j=2: \quad \alpha_2 \alpha_2 y_2 y_2 \mathbf{x}_2^\top \mathbf{x}_2 &= \alpha_2 \alpha_2 (4; 3)^\top (4; 3) \\ &= \alpha_2 \alpha_2 (16 + 9) = 25 \alpha_2^2 \end{aligned}$$

$$\begin{aligned} j=3: \quad \alpha_2 \alpha_3 y_2 y_3 \mathbf{x}_2^\top \mathbf{x}_3 &= \alpha_2 \alpha_3 (1)(-1)(4; 3)^\top (1; 1) \\ &= \alpha_2 \alpha_3 (-1)(4 + 3) = -7 \alpha_2 \alpha_3 \end{aligned}$$

6.2 实例

$$\mathbf{x}_1(3,3), \mathbf{x}_2(4,3), \mathbf{x}_3(1,1), y_1 = y_2 = 1, y_3 = -1.$$

$$\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i$$

$$\begin{aligned} i=3, j=1: \quad \alpha_3 \alpha_1 y_3 y_1 \mathbf{x}_3^\top \mathbf{x}_1 &= \alpha_3 \alpha_1 (-1)(1)(1; 1)^\top (3; 3) \\ &= \alpha_3 \alpha_1 (-1)(3 + 3) = -6\alpha_1 \alpha_3 \end{aligned}$$

$$\begin{aligned} j=2: \quad \alpha_3 \alpha_2 y_3 y_2 \mathbf{x}_3^\top \mathbf{x}_2 &= \alpha_3 \alpha_2 (-1)(1)(1; 1)^\top (4; 3) \\ &= \alpha_2 \alpha_3 (-1)(4 + 3) = -7\alpha_2 \alpha_3 \end{aligned}$$

$$\begin{aligned} j=3: \quad \alpha_3 \alpha_3 y_3 y_3 \mathbf{x}_3^\top \mathbf{x}_3 &= \alpha_3 \alpha_3 (-1)(-1)(1; 1)^\top (1; 1) \\ &= \alpha_3 \alpha_3 (1 + 1) = 2\alpha_3^2 \end{aligned}$$

6.2 实例

$$\mathbf{x}_1(3,3), \mathbf{x}_2(4,3), \mathbf{x}_3(1,1), y_1 = y_2 = 1, y_3 = -1.$$

$$\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i$$

$$= \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) \\ - \alpha_1 - \alpha_2 - \alpha_3$$

$$s.t. \quad \alpha_1 + \alpha_2 - \alpha_3 = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, 3$$

6.2 实例

将 $\alpha_1 + \alpha_2 = \alpha_3$ 代入下式

$$\frac{1}{2}(18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) \\ - \alpha_1 - \alpha_2 - \alpha_3$$

化简之后，得到如下等式：

$$S(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

6.2 实例

对 S 求偏导得到如下等式

$$\frac{\partial S(\alpha_1, \alpha_2)}{\partial \alpha_1} = 8\alpha_1 + 10\alpha_2 - 2 = 0$$

$$\frac{\partial S(\alpha_1, \alpha_2)}{\partial \alpha_2} = 13\alpha_2 + 10\alpha_1 - 2 = 0$$

联立上述2个方程组，解得

$$\alpha_1 = 1.5$$

$$\alpha_2 = -1$$

6.2 实例

□ 而 $a_2 = -1$ 的点不满于 $a_2 > 0$ 的条件，所以最小值在边界上取得。

□ 边界情况要么是 $a_1 = 0$ ，要么是 $a_2 = 0$ ，

□ 当 $a_1 = 0$ 时，把 a_1 的值往 s 对 a_2 的偏导里面带入计算得到 $a_2 = 2/13$ （满足条件）。

$$S(0, 2/13) = -2/13 = -0.1538。$$

□ 当 $a_2 = 0$ 时，把 a_2 的值往 s 对 a_1 的偏导里面带入计算得到 $a_1 = 1/4$ （满足条件）。

$$S(1/4, 0) = -1/4 = -0.25$$

显然后面的结果更小，所以： $a_1 = 1/4$ ； $a_2 = 0$ ； $a_3 = 1/4$

6.2 实例

- 到这里就能验证上面的结论了， a_1 和 a_3 是 x_1 和 x_3 的系数， x_1 和 x_3 是支持向量，而 x_2 不是，所以前面的系数是0。
- 因为根据 w 求解公式， $a_2=0$ ，所以 x_2 对 w 权的最后取值没有影响，所以 x_2 不是支持向量。
- 最后一步，带到上面的式子中求 w ， b ：

$$\begin{aligned}\omega &= \sum_{i=1}^n \alpha_i x_i y_i = \frac{1}{4} \times (3,3) \times 1 + \frac{1}{4} \times (1,1) \times (-1) \\ &= \frac{1}{4} \times (2,2) = \left(\frac{1}{2}, \frac{1}{2}\right)\end{aligned}$$

6.2 实例

$$\begin{aligned}\omega &= \sum_{i=1}^n \alpha_i x_i y_i = \frac{1}{4} \times (3,3) \times 1 + \frac{1}{4} \times (1,1) \times (-1) \\ &= \frac{1}{4} \times (2,2) = \left(\frac{1}{2}, \frac{1}{2}\right)\end{aligned}$$

得到 $w_1 = w_2 = 0.5$ 。

对于支持向量 x_1 , 计算 b 的值:

$$\begin{aligned}b &= y_i - \sum_{i=1}^n \alpha_i y_i (\Phi(x_i) \Phi(x_j)) = 1 - (\alpha_1 y_1 x_1^T x_1 + \alpha_3 y_3 x_3^T x_1) \\ &= 1 - \left(\frac{1}{4} \times 1 \times x_1^T x_1 + \frac{1}{4} \times (-1) \times x_3^T x_1\right) \\ &= 1 - \frac{1}{4} (18 - 6) = -2\end{aligned}$$

6.2 实例

$$\begin{aligned}\omega &= \sum_{i=1}^n \alpha_i x_i y_i = \frac{1}{4} \times (3,3) \times 1 + \frac{1}{4} \times (1,1) \times (-1) \\ &= \frac{1}{4} \times (2,2) = \left(\frac{1}{2}, \frac{1}{2}\right)\end{aligned}$$

对于非支持向量 x_2 , 计算 b 的值:

$$\begin{aligned}b &= y_i - \sum_{i=1}^n \alpha_i y_i (\Phi(x_i) \Phi(x_j)) = 1 - (\alpha_1 y_1 x_1^T x_2 + \alpha_3 y_3 x_3^T x_2) \\ &= 1 - \left(\frac{1}{4} \times 1 \times x_1^T x_2 + \frac{1}{4} \times (-1) \times x_3^T x_2\right) \\ &= 1 - \frac{1}{4} (21 - 7) = -5/2\end{aligned}$$

于是得到最后的决策边界为: $0.5 * x_1 + 0.5 * x_2 - 2 = 0$

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数

□ 6.4 软间隔与正则化


□ 6.5 支持向量回归

□ 6.6 核方法

6.3 线性不可分

-Q: 若不存在一个能正确划分两类样本的超平面, 怎么办?

-A: 将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分.



6.3 核支持向量机

□ 设样本 \mathbf{x} 映射后的向量为 $\phi(\mathbf{x})$, 划分超平面为 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$.

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)} - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \text{只以内积的形式出现} \end{aligned}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \boxed{\phi(\mathbf{x}_i)^\top \phi(\mathbf{x})} + b$$

6.3 核函数

- 基本想法：不显式地设计核映射，而是设计核函数。

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

- Mercer定理**(充分非必要)：只要一个对称函数所对应的核矩阵半正定，则它就能作为核函数来使用。

- 常用核函数：

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数


□ 6.4 软间隔与正则化

□ 6.5 支持向量回归

□ 6.6 核方法

6.4 软间隔

- Q:现实中, 很难确定合适的核函数使得训练样本在特征空间中线性可分; 同时一个线性可分的结果也很难断定是否是有过拟合造成的.
- A:引入“软间隔”的概念, 允许支持向量机在一些样本上不满足约束.



线性不可分情况下的线性分类器。

6.4 0/1损失函数

- 基本想法：最大化间隔的同时，让不满足约束的样本应尽可能少。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1} (y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) - 1)$$


其中 $l_{0/1}$ 是“0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

- 存在的问题：0/1损失函数非凸、非连续，不易优化！

6.4 替代损失

软间隔SVM



替代损失函数数学性质较好, 一般是**0/1**损失函数的上界

6.4 软间隔支持向量机

原始问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \end{aligned}$$

根据KKT条件可推得最终模型仅与支持向量有关, 也即hinge损失函数依然保持了支持向量机解的稀疏性.

6.4 正则化

- 支持向量机学习模型的更一般形式

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$



结构风险, 描述模型的某些性质



经验风险, 描述模型与训练数据的契合程度

- 通过替换上面两个部分, 可以得到许多其他学习模型
 - 对数几率回归(Logistic Regression)
 - 最小绝对收缩选择算子(LASSO)
 -

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数


□ 6.4 软间隔与正则化

□ 6.5 支持向量回归

□ 6.6 核方法


6.5 支持向量回归

特点：允许模型输出和实际输出间存在 2ϵ 的偏差。



6.5 损失函数

落入中间 2ϵ 间隔带的样本不计算损失, 从而使得模型获得稀疏性.



6.5 形式化

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \leq \epsilon + \xi_i, \\ & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \geq -\epsilon - \hat{\xi}_i, \\ & \xi_i \geq 0, \hat{\xi}_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha, \hat{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j) \kappa(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^m (\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^m (\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \leq \alpha_i \leq C, \quad 0 \leq \hat{\alpha}_i \leq C. \end{aligned}$$

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

大纲

□ 6.1 间隔与支持向量

□ 6.2 对偶问题

□ 6.3 核函数

□ 6.4 软间隔与正则化

□ 6.5 支持向量回归

□ 6.6 核方法

6.6 表示定理

支持向量机
$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

支持向量回归
$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

结论：无论是支持向量机还是支持向量回归，学得模型总可以表示成核函数的线性组合。

更一般的结论(表示定理)：对于任意单调增函数 Ω 和任意非负损失函数 l ，优化问题

$$\min_{h \in \mathbb{H}} F(h) = \Omega(\|h\|_{\mathbb{H}}) + l(h(\mathbf{x}_1), \dots, h(\mathbf{x}_m))$$

的解总可以写为
$$h^* = \sum_{i=1}^m \alpha_i \kappa(\cdot, \mathbf{x}_i).$$

6.6 核线性判别分析

□ 通过表示定理可以得到很多线性模型的“核化”版本

- 核SVM
- 核LDA
- 核PCA
-

□ 核LDA: 先将样本映射到高维特征空间, 然后在此特征空间中做线性判别分析

$$\begin{aligned} \max_{\mathbf{w}} J(\mathbf{w}) &= \frac{\mathbf{w}^\top \mathbf{S}_b^\phi \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w^\phi \mathbf{w}} \\ \downarrow \\ h(\mathbf{x}) &= \mathbf{w}^\top \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}_i, \mathbf{x}) \\ \max_{\boldsymbol{\alpha}} J(\boldsymbol{\alpha}) &= \frac{\boldsymbol{\alpha}^\top \mathbf{M} \boldsymbol{\alpha}}{\boldsymbol{\alpha}^\top \mathbf{N} \boldsymbol{\alpha}} \end{aligned}$$

线性不可分情况下的非线性分类器。

Take Home Message

- 支持向量机的“最大间隔”思想
- 对偶问题及其解的稀疏性
- 通过向高维空间映射解决线性不可分的问题
- 引入“软间隔”缓解特征空间中线性不可分的问题
- 将支持向量的思想应用到回归问题上得到支持向量回归
- 将核方法推广到其他学习模型

成熟的SVM软件包

- LIBSVM

<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>

- LIBLINEAR

<http://www.csie.ntu.edu.tw/~cjlin/liblinear/>

- SVM^{light}、SVM^{perf}、SVM^{struct}

http://svmlight.joachims.org/svm_struct.html

- Pegasos

<http://www.cs.huji.ac.il/~shais/code/index.html>